- **Adam 优化器**
  - 除参数震荡、梯度频繁改变方向外，可能还有 **不同参数的梯度数值差异较大、某些梯度长期过大或过小等问题** 。
  - **思考：**
    - 既然梯度的数值会突变，某些参数长期过大/过小，我们能否引入一个变量，让它体现先前梯度更新的幅度，同时适当减小/增长变量更新的步长？
    - 梯度有正有负，我们可以 **取绝对值或者平方后开根** ，来衡量梯度的大小，但是由于 **绝对值不利于求导** ，于是我们选择平方。引入变量 v_t，使得 $v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$ ，其中为了 **不让** v_t **过大** ，我们选择让 v_{t-1} 、 g_t^2 **的权重之和为1** 。
    - 那么把这个变量放在哪个位置，可以在梯度小/大时，增加/减小步长呢？
    - 不妨把它 **放在更新项的分母** 上，为了不让 **平方导致数量级剧变** ，我们给它 **开根号**，为了 **不让分母为0** ，我们还要在 **分母加上极小量** ϵ 。
    - 问题又来了，第一代的 **历史值为零** ，我们，我们还 **给当前的梯度乘了小于1的** $beta_2$，那么这次 **更新幅度可能太大** 了！我们不妨引入 $hat v_t = \frac{v_t}{1-\beta_2^t}$，从而避免 **初始偏差**。后期数值稳定时，为了减弱 β_2 的影响，我们取它的 **t 次方** 。
    - 结合对 v_{t-1} 、 g_t^2 的权重之和为1的处理，你是否还记得动量法还有一个 v_{t-1}，在 Adam 优化器，我们叫它 m_t，同样为了 **不让** m_t **过大**，我们也引入 m_{t-1} 、 g_t 权重之和为 1 。
    - 同样因为第一次没有历史值，直接乘以小于一的 β_1 使得 m_t 较小，我们也来个 $\hat m_t = \frac{m_t}{1-\beta_1^t}$ ，对它进行修正。
    - 于是，我们得到了 **Adam优化器**

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$$

$$\hat m_t = \frac{m_t}{1-\beta_1^t}$$

$$\hat v_t = \frac{v_t}{1-\beta_2^t}$$

$$\theta_{t+1} = \theta_t - \eta \frac{\hat m_t}{\sqrt{\hat v_t} + \epsilon}$$

  - m 相当于 动量法中的 v ；
  - v_t 用于调整步长；
  - ϵ 极小，用于防止 v_t = 0；
  - $\hat m$ 、 $\hat v_t$ 是为了减弱第一代历史值为零带来的影响（初始偏差），随训练时间增长 β_1^t 、 β_2^t 会趋近于零。
  - 当前 mini-batch ——→ 计算梯度 g ——→ 看看最近梯度总体朝哪个方向（ m ） ——→ 看看最近梯度通常有多大（ v ） ——→ 修正刚开始训练时的偏差 ——→ 根据梯度大小自动调整实际步长 ——→ 更新参数