- **本体大部分学习由 ChatGPT 教授，另外还观看了 B 站、YouTube 上的相关视频**。
- B 站：跟李沐学 AI ———— 49.样式迁移（动手学神经网络v2）
- 与 ChatGPT 的对话链接：
  - https://chatgpt.com/share/6ad8c23b-e4e8-83e8-93e4-80e04ffb5e3a
  - https://chatgpt.com/share/6ad8c24d-6f2c-83ee-a1b7-08658fe37d4a
- **小登的题解较长，感谢学长的悉心批改。**

Cyber Painter

I - 模型预训练与微调

1. 查找模型预训练与模型微调相关知识，并了解其好处。
   - **预训练（Pretraining）**：在某个人物的数据上训练模型，获得较好的模型架构和参数，从而得到一个通用模型，为后续任务提供基础。
   - **微调（Fine-tuning）**：以**预训练得到的模型为起点，针对后续任务训练全部或部分参数**的过程。
   - **好处**：
     - 通过预训练，我们可以**使用已有的模型架构和参数**，在**训练后续任务的模型**时：
       1. 从预训练模型参数开始梯度下降，**训练所需时间短，训练速度快**。
       2. **对训练数据需求小**。
       3. **计算资源少，对设备要求低**。
       4. **继承已有模型的能力，相较于从零开始，可能改善模型性能**。
2. 了解冻结参数的作用，模型微调时超参数该如何设置。
   - **作用**：
     1. **降低训练成本，提高训练速度**。
     2. **保留有效参数**。
     3. 降低可更新参数的量，**减少过拟合风险**。
     4. 在本题中，冻结 VGG 的所有参数，使得处理内容照片、风格照片和生成照片的规则相同，确保**特征提取的一致性**。
   - **设置**：
     - **学习率**：由于预训练的参数已经与新任务的最佳参数比较接近，所以**应使用较小的学习率**。
     - **Batch**：**设备内存、显存性能较好的时候，可以选择较大的 Batch 从而增加一次参数更新依赖的数据量，**反之，可以适当调小 Batch**。co
     - **Epochs**：**对比验证集和测试集的损失和准确率，判断是否欠拟合者过拟合，从而调整 Epochs**，当然也可以引入**早停机制**。
     - **优化器**：常用的优化器有 SGD，Adam，动量法等，但是**最终要根据实验结果选择最佳优化器**。
3. 在风格迁移领域预训练模型有什么作用。
   - **作为 “特征提取器”**：经过预训练后，模型已经有了相当强的特征提取能力。我们通过把内容图片、风格图片和生成图片输入预训练模型，就可以在神经网络的某些层得到它们的特征表示。我们进而通过这些内容特征和风格特征，得到内容损失和风格损失，最后通过对生成图片实施梯度下降，实现生成图片的优化。

II - 初识风格迁移

III - 代码细节

1. 如果所选的风格图片和内容图片尺寸相差太大，会有影响吗？
    - **会**有影响，但**尺寸差异过大并不一定严重影响风格迁移，这两张图片也不一定要有相同的尺寸**。
    - 为了便于计算内容损失，我们通常确保**内容图片和生成图片的尺寸一致**，但是当我们使用 Gram 矩阵计算风格损失时， **Gram 矩阵的大小只与输入通道数有关**。至于由于尺寸不同造成的 **Gram 矩阵元素的数值差异**，我们可以通过 **Gram 矩阵归一化**减少其影响。因此，风格图片和内容图片完全可以有不同的尺寸。
    - 如果**过度缩放风格图片，可能改变原本的纹理、丢失细节等**。并且使用**分辨率适当大的风格图片，更有利于保留风格的细节**。
    - 但是当风格图片**分辨率过大**，会显著增加**计算资源**。而在固定的卷积核下，分辨率很大的风格图片虽然可以保留风格的细节，但是由于**生成图片的分辨率小，无法体现那么多细节和纹理**，这时可能**收效不大**。
    - 因此，我们应该**综合计算资源、对生成图片效果的需求等，适当选择内容图片和生成图片的尺寸**。
2. 请简要了解内容损失、风格损失、全变分损失的数学原理，并用自己的话进行解释。
    - **内容损失**：
        - 我们希望生成图片和内容图片，**在相同的空间位置保存相同的内容特征**，比如画面中心都是向日葵、向日葵的花和叶片的位置等。
        - 如果**直接比较原始生成图片和原始内容图片的像素差异，那么生成图的纹理、细节等难以发生迁移**。
        - 因此，我们可以**抽取生成图片和内容图片在某些相同卷积层得到的特征图，计算两张图片每个通道的特征图在相同位置的数字的均方误差**，这个均方误差就**衡量了生成图片和内容图片在相同位置的内容损失**。
        - **均方误差的数学公式**：

$$L_{\text{content}} = \frac{1}{N} \sum_{k=1}^{N} \left(F_l(G)_k - F_l(C)_k \right)^2$$

            - C：内容图片。
            - G：生成图片。
            - $F_l(I)$：图片 I 在选定 VGG 网络层 l 的特征。
            - N：参与比较的特征数值总量。
    - **风格损失**：
        - 我们要**把风格图片的纹理、细节、笔触等迁移到生成图片**，但是**不要求这些纹理、笔触在相同位置出现**。
        - 通常将某一层所有特征通道(N)两两进行内积，得到一个矩阵($N \times N$)，这个矩阵叫做**Gram 矩阵**。
        - 为什么 Gram 矩阵可以衡量风格呢?
        - 因为**内积能够在一定程度上反映不同特征图的响应程度**。经过卷积层计算得到的**不同特征图反映了不同的特征**，比如有的反映了纹理，有的反映了某个边缘等，通过不同的**特征图作内积，我们就可以得到这些特征图之间的响应程度**。例如 $[2,1]$ 反映了纹理，它对 $[2,1]/[1,2]$ 这两个反映边缘的特征图的响应程度是不同的。因此， Gram 矩阵能**一定程度得反映图片的风格**。、
        - **归一化 Gram 矩阵**：

$$M_{ij}(F) = \frac{1}{HW} \sum_{p=1}^{HW} F_{i,p} F_{j,p}$$

        - i, j 指两个特征通道。
        - p 特征通道上的空间位置。
        - $F_{i,p}$ i 特征通道 i 在 p 位置的数值。
        - HW 特征通道的空间位置总量。
    - 类比内容损失对特征图的数值做均方误差，我们可以得到 **Gram 矩阵构建的均方误差**：

$$L_{\text{style}} = \frac{1}{C_f^2} \sum_{i=1}^{C_f} \sum_{j=1}^{C_f} \left(M_{ij}(G) - M_{ij}(S) \right)^2$$

        - $M(G)$：生成图片在选定网络层的 Gram 矩阵。
        - $M(S)$：风格图片在同一层的 Gram 矩阵。
        - C_f：该层特征通道数量。
- **全变分损失**：
    - 有时，我们会发现只是用风格损失和内容损失时，生成图片上会出现一些**剧烈的像素变化或者噪点**。
    - 比如当我们的内容图片是向日葵，风格图片是梵高的星月夜，黄色背景上可能突然出现一点点类似星星笔触的区域。
    - 但是，**风格损失和内容损失完全可能很低**，因为是生成图片包含了内容图片的结构和风格图片的笔触、纹理等。
    - 因此，我们希望引入一种**正则化项，防止生成图片过度拟合内容图片和风格图片的某些像素，防止出现剧烈的相邻像素变化。**
    - 我们不妨使用**生成图片相邻像素的均方误差来作为这个正则化项，这个正则化项也可以叫做全变分损失**。
        - 鉴于我们在内容损失和风格损失都使用了 MSE 。我们处理总变分损失是也使用 MSE，是为了**消除可能存在的、由运算方式引起的差异**。
        - 但在其他情境下完全可以用相邻像素差的绝对值的平均值来作为总变分损失。

$$L_{\text{TV}} = \frac{1}{(H-1)W} \sum_{i=1}^{H-1} \sum_{j=1}^{W} (P_{i+1,j} - P_{i,j})^2 + \frac{1}{H(W-1)} \sum_{i=1}^{H} \sum_{j=1}^{W-1} (P_{i,j+1} - P_{i,j})^2$$

        - H、W 分别是某个通道的高和宽。
        - $P_{i,j}$ 是某个通道上某个像素在 (i, j) 的数值
- 最终，我们分别**赋予上面损失一定的权重，来作为风格迁移的损失函数**。

3. 风格损失中 gram 矩阵的作用是什么？为什么内积能表示两个通道间的相似度？
- **作用**：衡量各个通道自己的响应程度，和不同特征通道之间的两两响应程度，从而便于计算风格损失。这种响应程度，实际上是特征通道的整体统计关系。
- **原因**：严格来讲，内积并不能反映两个通道的相似程度，但是可以衡量通道的响应程度。
    - 内积的大小，由两个向量的**大小和夹角**决定，因此内积可以在一定程度上反映**两个向量的整体关系**。
    - Gram 矩阵中，对角线元素是特征通道自身与自身作内积，这反映了**某个通道自己与自己的响应程度**；非对角线元素来自不同通道的两两内积，反映了**不同通道之间的响应程度**。
    - 由于**风格（笔触、纹理等）对具体的空间位置没有要求，所以我们希望的到描述整体特征关系、而不依赖具体位置的数学表示**。
    - 显然，内积可以起到反映这种整体特征关系的作用。
    - 例如：生成图片和风格图片在某个卷积层得到两个反映纹理的特征通道分别是 $[1, 2]$ 和 $[2, 1]$ ，尽管两个张量每个位置的数是反的，但是自身与自身的内积是相同的，因此我们可以认为两幅图片有类似的纹理。

        - 因此，我们通过计算内积得到 Gram 矩阵，再计算生成图片和风格图片的 Gram 矩阵的 MSE，就可以得到风格损失，从而**在一定程度上衡量两张图片在艺术风格上的差异**。
4. 请比较风格损失与内容损失的差异，为什么 gram 矩阵更适合捕捉风格？
    - **差异**：
        - **核心区别在于比较的对象、对空间位置的要求不同**，因此处理方式不同。
        - **内容损失**：
            - **关注生成图片的某个空间位置是否含有与内容图片相同的结构等**。比如内容图片的中间是一朵向日葵，向日葵是圆的，那么风格图片的中间应该也是向日葵，向日葵也应该是圆的。
            - 因此，我们**直接比较选定的卷积层输出的特征图对应位置的数值差异**。
        - **风格损失**：
            - **关注生成图片是否含有和风格图片一样的笔触、纹理等艺术风格，而这些笔触和纹理完全可以不在同一个空间位置。**比如梵高的星月夜有明显的油画风格，但是生成图片并不需要在背景上生成旋转的星星。
            - 因此，我们**比较 Gram 矩阵的差异**。
    - **原因**：
        - Gram 矩阵是特征通道的两两内积构成的对称矩阵。而**卷积层可以数字化图片特征，我们得到的特征通道，实际就是对某个内容、风格的数字表示。经过预训练的模型，不同的特征通道能够体现固定的特征**。
        - 内积的大小，由两个向量的**大小和夹角**决定，因此内积可以在一定程度上反映**两个向量的整体关系**。
        - Gram 矩阵中，对角线元素是特征通道自身与自身作内积，这反映了**某个通道自己与自己的响应程度**；非对角线元素来自不同通道的两两内积，反映了**不同通道之间的响应程度**。
        - 由于**风格（笔触、纹理等）对具体的空间位置没有要求，所以我们希望得到描述风格整体特征关系，而不依赖具体位置的数学表示**。
        - **对于某个特定的特征图，我们在所有通道进行相同的空间位置变换，比如调换第一个元素和第二个元素的位置，那么 Gram 矩阵保持不变**。
        - 因此 **Gram 矩阵适合描述不依赖空间位置的特征的统计信息**，但不能完全描述一个画作的艺术风格。
5. 在计算内容损失和风格损失时，为什么通常要将内容图和风格图对应的目标特征从计算图中分离？
    - 我们需要**优化的是生成图片的像素，而内容图片和风格图片是参考目标**。将内容图和风格图对应的目标特征从计算图中分离，**可以避免不必要的梯度追踪，减少反向传播时不必要的的计算资源**。
    - 代码实现：
        - ```
          target = model(content/style)
          target = target.detach()
          ```

          将张量从自动求导关系中分离。常在已经计算过的张量后使用。
        - ```
          with torch.no_grad():
              target = model(content/style)
          ```

          自动关闭梯度追踪，即目标特征不需要记录梯度计算关系。常用于直接提取目标特征

6. 使用迁移学习来提取特征时应设置为评估模式，这和冻结参数是否是一回事？
    - **不是**：
        - `model.eval()` 将模型切换为评估模式。这改变的是**某些具有训练和评估两种模式的网络层在计算时的行为**。
            - 例如：Dropout 停止随机失活、把 BatchNorm 使用的标准化数据切换为运行统计量等。
        - `model.requires_grad_(False)` 冻结模型参数。这**让模型参数不需要梯度**，进而使模型的参数不计算梯度，也不进行更新。
7. 如何从模型中抽取合适的层作为内容层和风格层，这样做的依据是什么？
    - 如何选：
        - 一种常见的方法是，**在较深的卷积层提取内容特征，在不同深度的卷积层提取风格特征**。
    - **依据**：
        - 随着神经网络越来越深，感受野通常越来越大。因此**较浅的卷积层往往保留了纹理、边缘等细节，较深的卷积层往往保留了形状、复杂图案等范围较大的结构**。
        - **为了保留内容图片的结构、大体形状等，给与纹理、笔触等改变的空间，我们选用较深的网络层作为内容层**。
        - **为了模仿风格图片的纹理、笔触以及整体的视觉特征（不同空间尺度的风格特征），我们选择深度不同的网络层作为风格层**。
        - 同时，**不选用较浅的网络层作为内容层，还可以避免生成图片过分学习内容图片的局部细节，导致风格迁移效果不佳**。
8. 风格迁移任务中适合使用 L-BFGS 优化器，相较于 Adam、SGD 的特点是什么？（当然，你可以选择后两种方法，通过实际训练挑选出来最适合该任务的优化器）
    - 关于 Adam、L-BFGS 的具体推导和深入理解，不适合在本题解中展开，因此小登**把这两个优化器的相关内容单独放在两个 Markdown 里，提交到与本体仓库里**。
        - **欢迎学长指正小登对这两个优化算法的理解、指出推导过程中不合理之处，小登将不尽感激。**
        - 如果小登**没有附上 L-BFGS 的文件，是因为小登比较菜，还在赶做题进度，欢迎学长面试拷打**。
    - **SGD**：
        - 在机器学习中，我们常把小批次梯度下降叫做 SGD ，即取一个批次所有样本计算出的的梯度平均值，作为更新参数的梯度。
        - SGD 的**好处**是**综合 Batch 的样本数据**，既实现了单次更新的计算成本比 GD 小，也降低了单个样本的噪音、细节对参数更新的影响。
        - 但是，SGD 参数更新只由**梯度和固定的学习率**决定，且**对学习率敏感**。当人工选择的学习率较大大，参数更新速度快，但是参数收敛效果差，甚至产生发散；学习率较小，参数容易收敛，但是参数更新的速度比较慢、容易陷入局部最小值或者鞍部等。
    - **Adam**：
        - Adam 继承了**动量法“引入历史梯度方向对新梯度影响”的机制，又根据历史梯度的大小，调整参数更新的步长**。
        - 它的**优点**是根据历史梯度调整新的更新幅度：
            - 当梯度**长期较小**的时候，可以放大参数更新的步长，加快参数更新的速度、有效防止参数陷入局部最小值等；
            - 当参数**长期较大**时，可以减小参数更新的步长，有效防止参数的震荡和发散、加快参数收敛等；
            - 当梯度**方向长期不变**时，可以加快参数更新的速度；
            - 当梯度**方向突变**时，可以保留部分历史方向状态，减小方向突变的影响。

        - 由于 Adam 算法更新速度快、收敛稳定、能够适应大多数参数更新的情况，常被称作**万金油优化器**。
        - 但它仍有**局限性**，比如，超参数较多，又对超参数比较敏感，不当的超参数选择对最终的参数更新效果影响很大。在风格迁移中，由于
    - **L-BFGS**：
        - **简略阐述**
            - L-BFGS 是对 BFGS 求拟合海森矩阵逆的优化。
            - BFGS 参考了**梯度下降算法和牛顿法**，是一种拟牛顿算法。在不启动线搜索算法时，L-BFGS 与常规的 SGD 算法的更新公式相对比，相当于把学习率换成了步长系数，给梯度右乘一个**负的拟合曲率（二阶导数）矩阵的逆（拟合海森矩阵的逆）作为搜索方向**。
            - BFGS 解决了牛顿法每次都要计算高维度二阶导数矩阵的问题，选择使用历史信息拟合出这个二阶导数矩阵，这****很大程度上的减少了计算量，但是每次都要储存过去所有的历史信息，并计算出拟合海森矩阵，只需要大量的内存资源和计算资源**。
            - L-BFGS 在 BFGS 的基础上，牺牲了一定拟合矩阵和真实矩阵的相似程度，**只储存有限次的历史信息**，并且中间过程不需要储存庞大的矩阵信息，**只需要确定一个极其简单的初始矩阵，就可以借助简单的内积和加减，得到最终拟合海森矩阵的逆与梯度的乘积，这极大的降低了对计算资源和储存资源的需求**，特别是对于处理图片等数据。
        - **特点分析：**
            - 从**数学**角度看，SGD 的参数更新利用了当前位置的**线性一阶导**寻找更新的方向和大小，而 L-BFGS 实际上是利用泰勒展开，在一阶线性导数的基础上，利用二阶导数，生成一个**二次型函数**拟合当前位置的损失函数情况。
                - 也因此，这类拟牛顿法在**线性和类似二次型损失函数上很有效**，但是在比较复杂的，加入指数、间断的损失函数上表现相对不佳。
            - 从**公式**上看，L-BFGS 的梯度除以曲率，有利于**在梯度变化较快的时候降低参数更新速度**，在**梯度较为平缓的时候加快参数更新，有利于参数的更新和收敛**。
            - 同时，尽管在牛顿法、BFGS 上进行了显著优化，L-BFGS **对计算资源和内存资源的要求仍然很高**。
    - **对于本题的风格迁移**，我们大量使用**均方误差作为损失函数**，这本身就有利于 L-BFGS 的拟合，因此使用 L-BFGS 可能很有效，但这不说明它一定比 SGD、Adam 效果更好，最终**选择需要根据实验结果**，这也正是题干提倡我们做的。
9. 简要总结一下风格迁移主循环的流程。 a. **清除旧梯度**。 b. 将当前生成图片经过某型特定的层，**提取其特征**。 c. 计算三种损失函数并加权，获得**总损失函数**。 d. **反向传播**，计算生成图片的梯度。 e. 优化器**更新生成图片的像素值**。
    - 重复上面的循环，直到达到最大更新次数或者停止条件。
10. 简述风格迁移中前向传播和反向传播的流程。

- **前向传播**：
    1. 将生成图片**输入**冻结参数的预训练模型；
    2. 按照**从输入到输出的顺序依次经过模型的神经网络**；
    3. 得到选定网络层的**特征图**；
    4. 计算总**损失函数**。
- **反向传播**：
    - 从最终的**总损失函数**开始，按照复合函数的**链式法则**，沿着与**前向传播相反**的方向，计算**生成图片张量的梯度**。

11. 风格迁移任务中有哪些超参数？各个损失间的权重该如何设置？

- **超参数**：输入图片的尺寸、生成图的初始化方式、各种损失的权重、选定的风格层和内容层、各个层相对于对应损失的权重、优化器类型、学习率、最大外层循环次数。对于 L-BFGS 来说，还有最大内部优化次数、保留历史信息的最大轮数、是否使用线搜索等。
- **权重设置**：
  - 权重控制**各个损失对总损失的贡献**，会影响反向传播计算出的**梯度大小和方向**，进而影响**参数更新**。
  - 而**不同损失的算法**不同，不同内容图片和生成图片对结果的影响也不同，我们希望得到的最终效果也因人而异，因此我们**不能套用某个项目的权重，或者设定固定的权重，而是要根据实验结果适时调整**。
  - 一般来说，我们可以参考**损失的算法、损失的大小、梯度的大小和方向、实际的生成效果**来设置权重。
  - 通常可以采用以下几种方式设置权重。
    1. 先**将内容损失固定为 1或者其他合适的常量， 作为参考尺度，根据损失算法选择另外两个损失的初始权重**，根据最终生成图片的效果**调整风格权重和总变分权重**。
    2. 先**计算初始生成图片的损失，根据这个初始损设置初始权重**，然后**根据生成图片的效果调整权重**。

12. 模型的总损失越小迁移效果越好吗？在合成图片过程中你是如何调参的？
    - **不一定**:
      - 首先，模型的总损失是**是数学目标**，风格迁移效果需要**人的审美**来评价。
      - 其次，为了实现较好的迁移效果，我们要****选择合适的损失函数，并合理配置损失权重**，但是如果单纯为了降低总损失，完全可以降低某些权重，或者直接缩小所有权重，但这会影响参数的更新，并最终影响迁移效果。
    - **调参**：先选定一套初始超参数设置，然后控制单一变量进行调参，记录每次调试后的结果，最后对比总损失的变化、视觉效果、计算资源等，确定最终的超参数。

IV - 风格迁移的发展（选做）

- **小登完成了 1.风格强度控制 2.多风格融合。并在模拟《星月夜》和中国山水画时，调整了全变分损失、更换了全变分损失算法、改变了风格层、改变了生成图初始化方案等。**
- 小登**使用 ChatGPT**生成了不同超参数下，不同 group （内容图与生成图至少有一个不同）的损失和生成图效果对比，保证单一变量的两两效果对比，超参数对比表格等。
- **请学长前往库中 report.html 查看这些对比图。**

小登的图片

- 小登在此附上一些个人认为**比较有风格和代表性，但是审美效果可能不好的图片**。

- 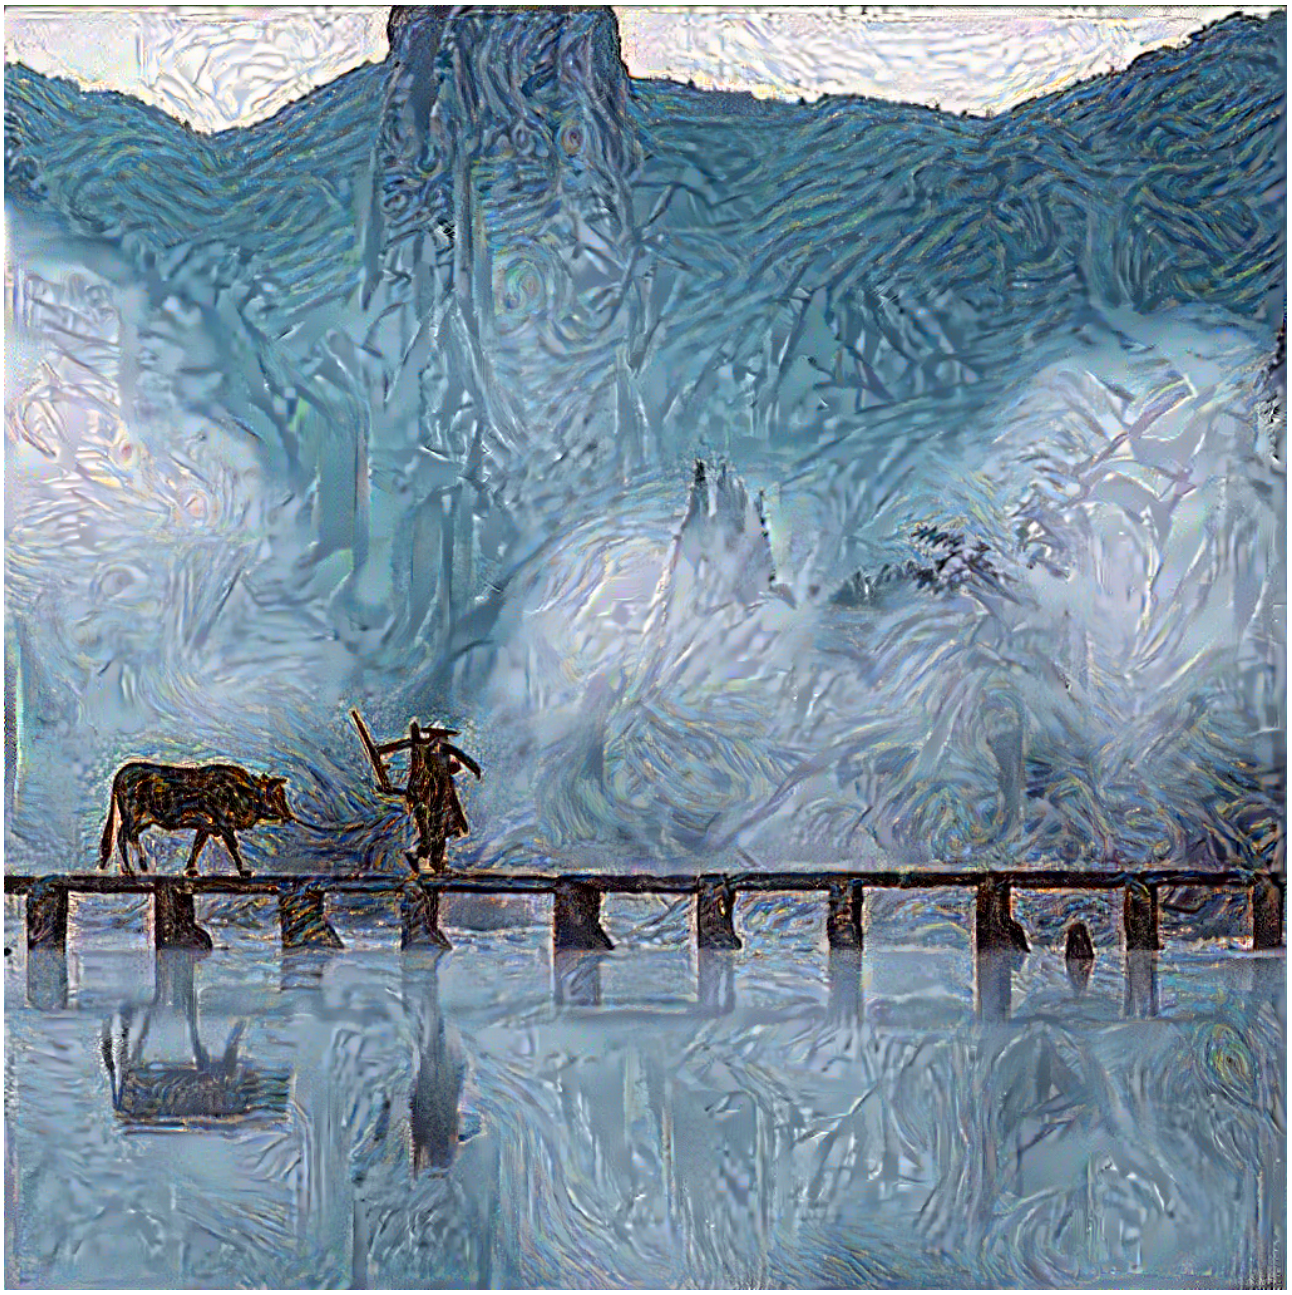

-

- 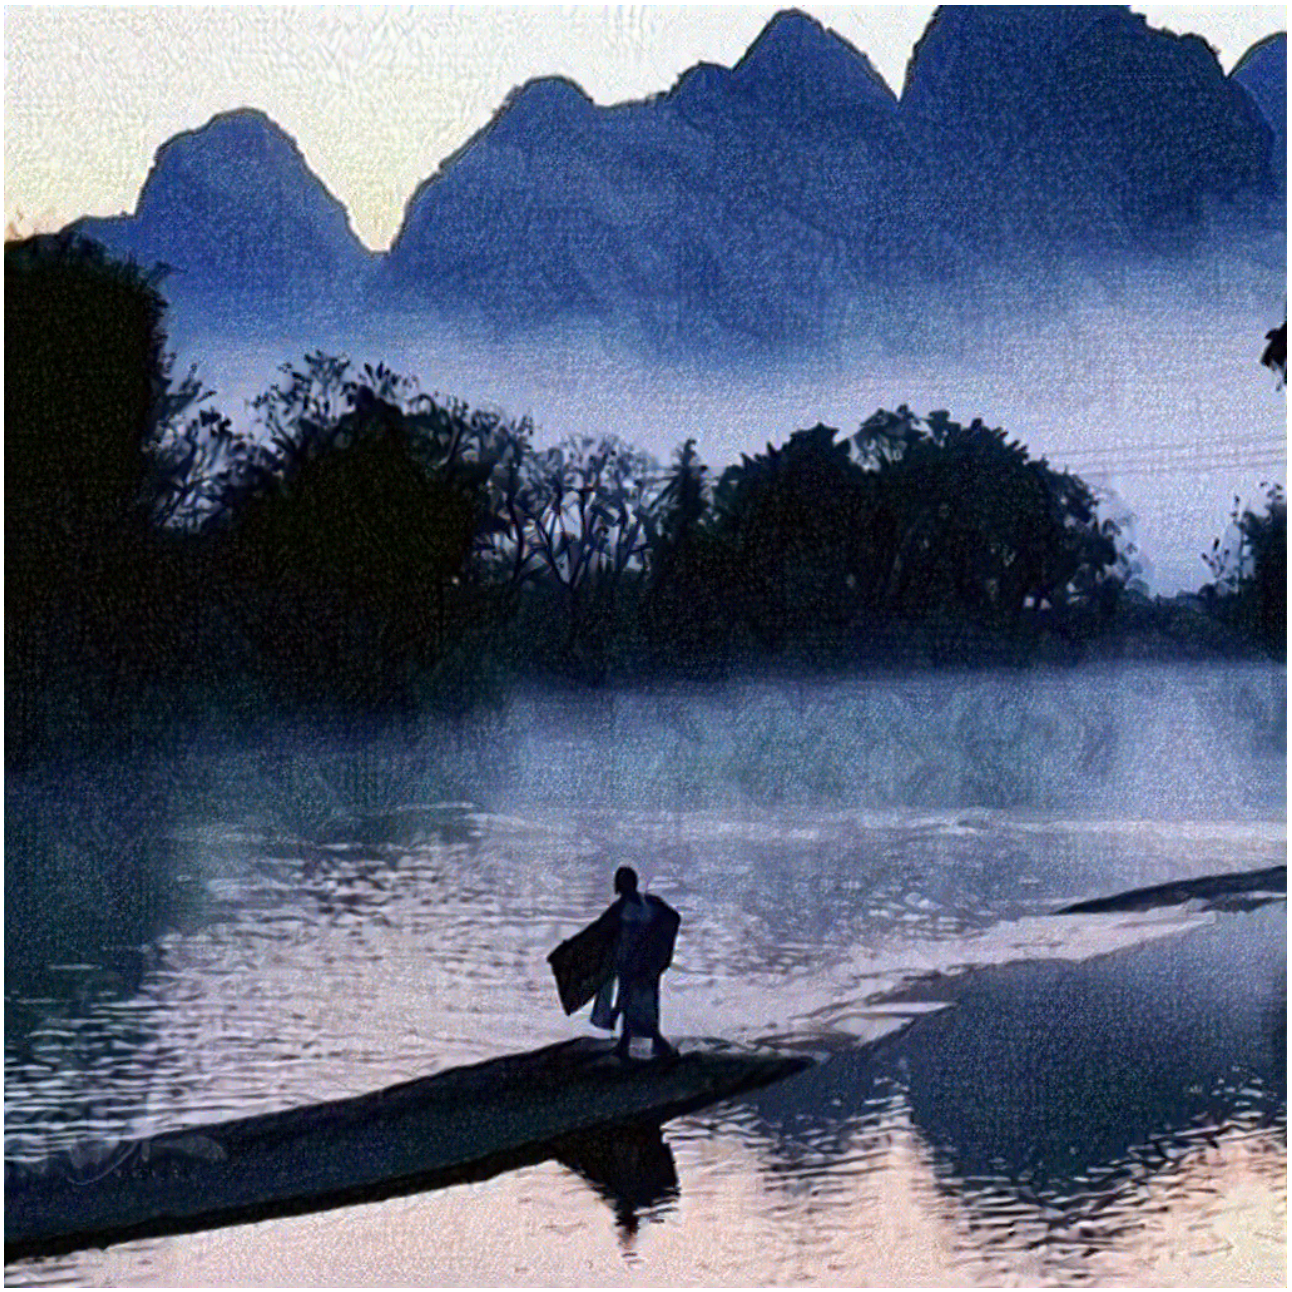

-

- 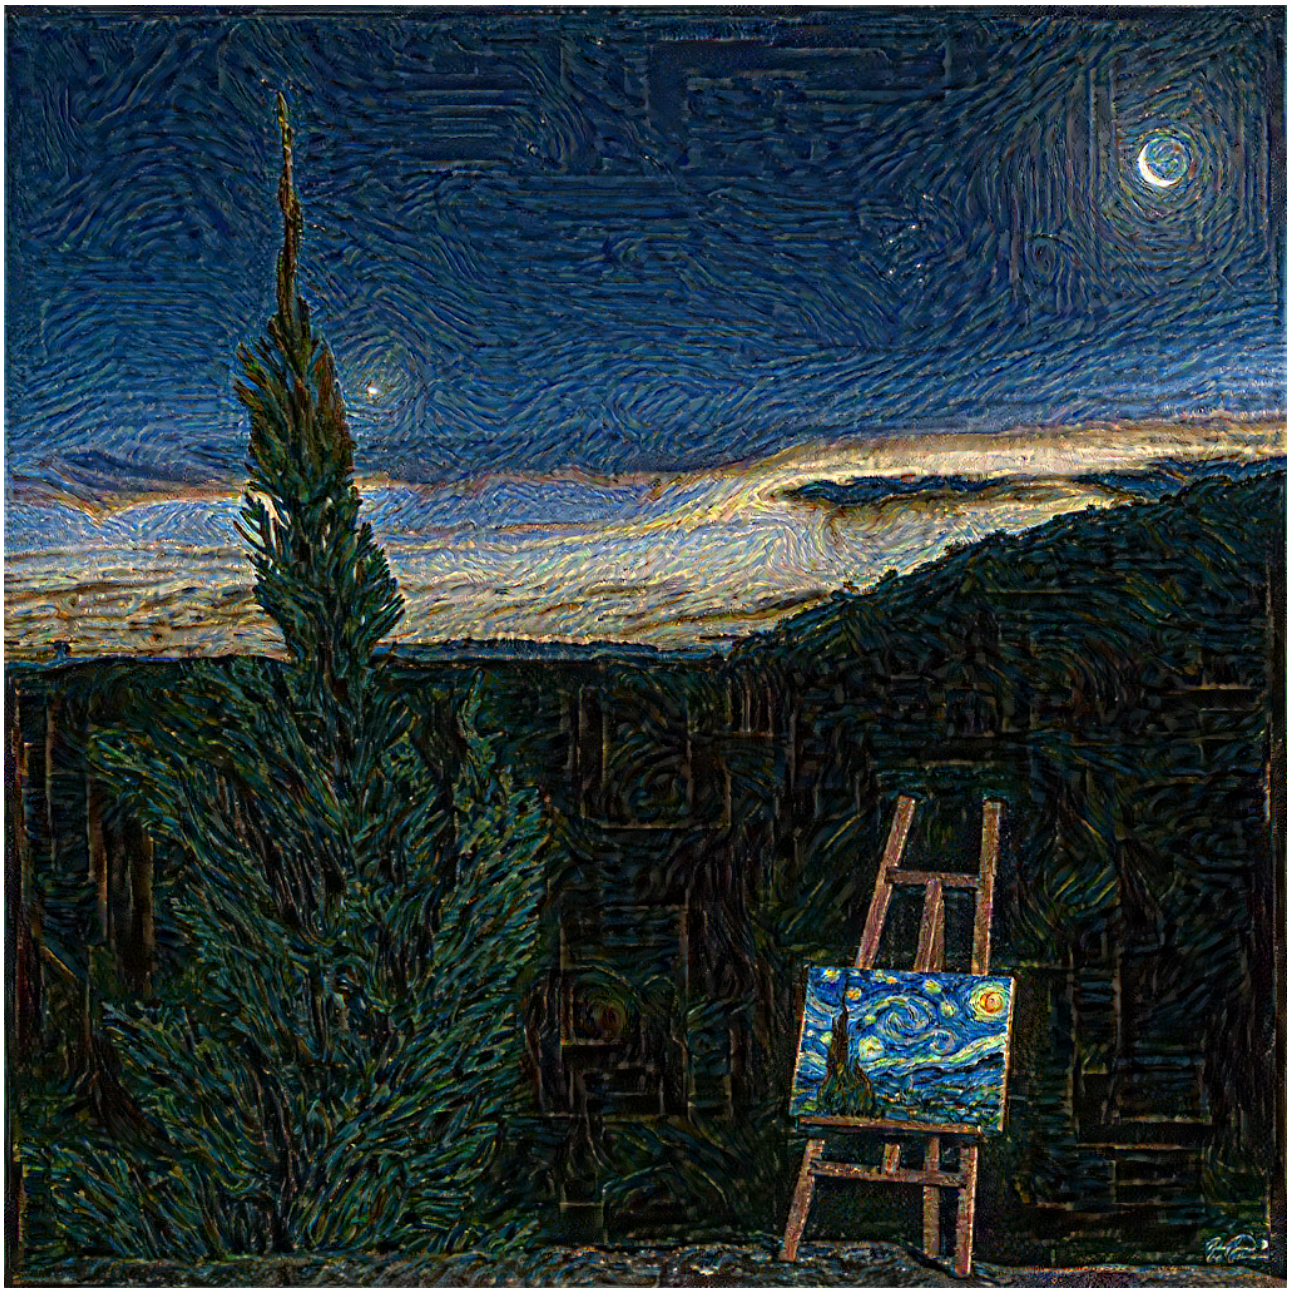

- 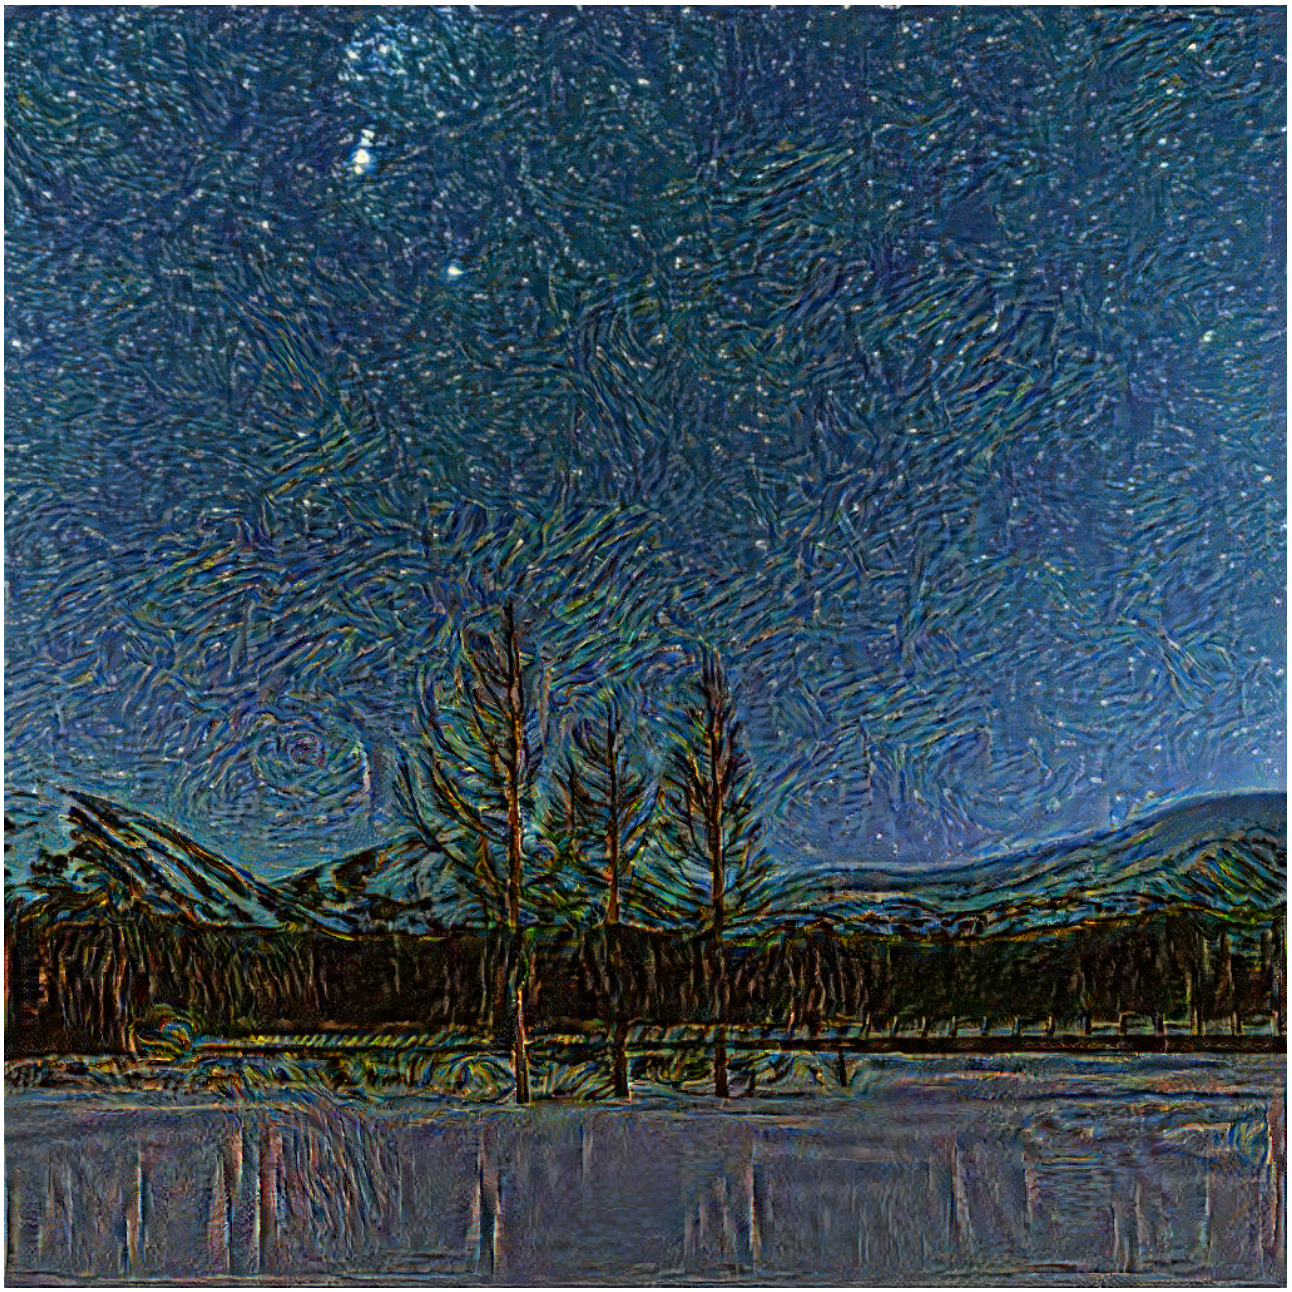

- 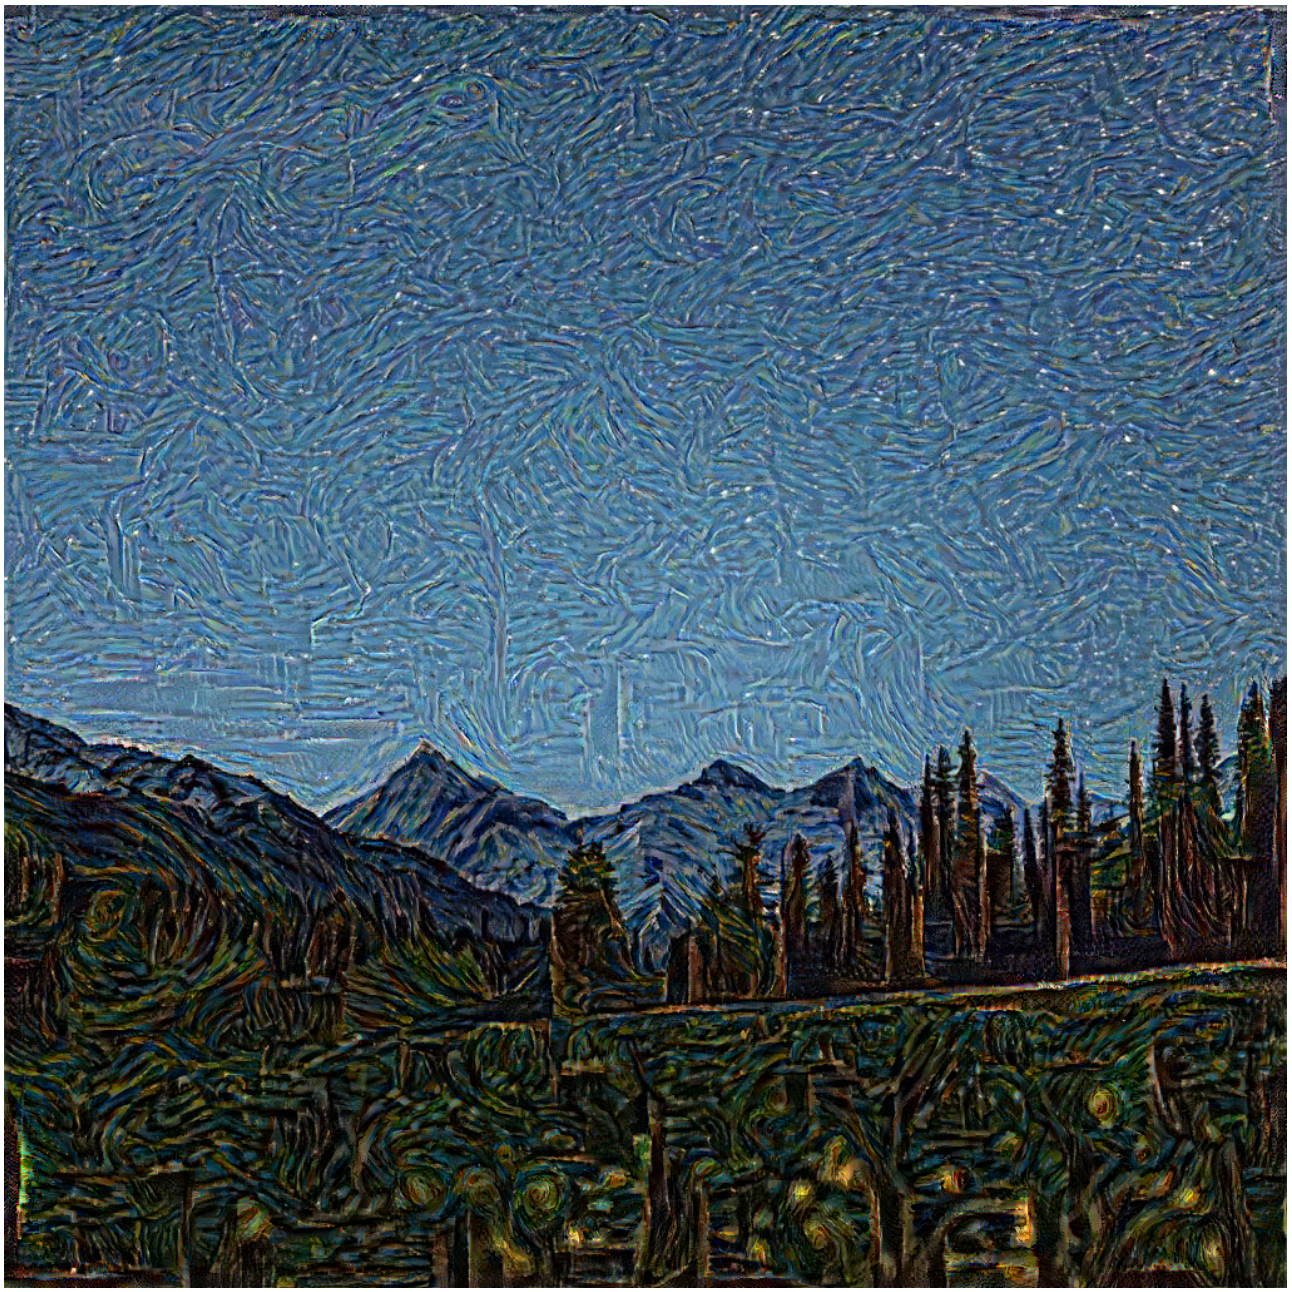

-
-

- 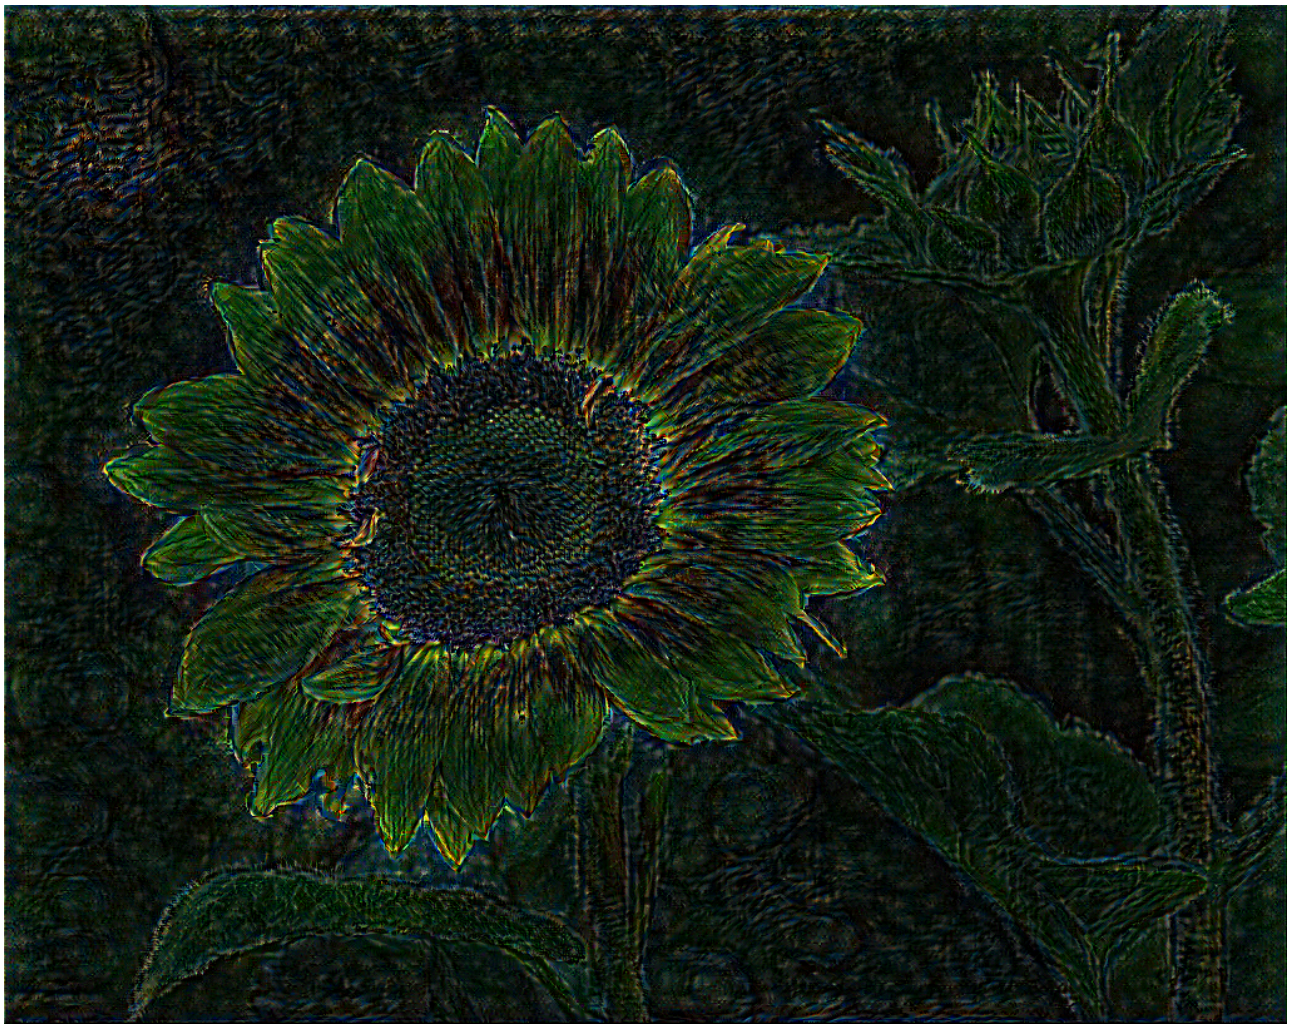

小登的思考、总结与问题

- **Adam 与 L-BFGS**：
  - **大多数情况下，L-BFGS 确实比 Adam 参数更新快、效果好、更新稳定。**
  - 但是小登观察到，两者还有**其他不同**：
    - 在scene_3 的水墨画迁移实验中，在第二次代码里，小登大大降低了风格迁移的参数，虽然两种优化器**最终损失较低且相近**，但是**L-BFGS 迁移出来的图片，风格整体感强，明显减少了很多细节纹理、笔触。**
      - Adam

-
- L-BFGS

    - **小登没有思考出来原因，经过查资料、询问 ChatGPT，得出的结果是，可能因为某些偶然因素（比如落在了不同的损失最小区域），造成了风格的不同。**
    - **这也侧面印证了，尽管损失相近，图片的风格和审美效果也完全可以不同。**
- L-BFGS **可能由于起初损失函数梯度较小，陷入局部最小值。**但是 Adam 出现这种问题的可能性更小。
    - 小登还在一次未保存的实验记录观察到：可能**由于起初损失函数梯度较小，L-BFGS 又是模拟二次型函数，一开始就陷入了局部最小值，损失居高不下**；但是 **Adam 由于其在梯度小时放大步长的特性，最初更新得很快，没有一开始就陷入损失最小值，最终实现了较好的参数更新**。
        - 可惜这次实验被小登当成废品删了。（掩面长叹）
- **小登在向日葵与星月夜的风格迁移实验中，曾使用零张亮初始化生成图片。**
    - 尽管最终生成的图片都很暗，但是 **L-BFGS 图片的亮度明显强于 Adam**。 但是损失依然相似。
    - L-BFGS:

- 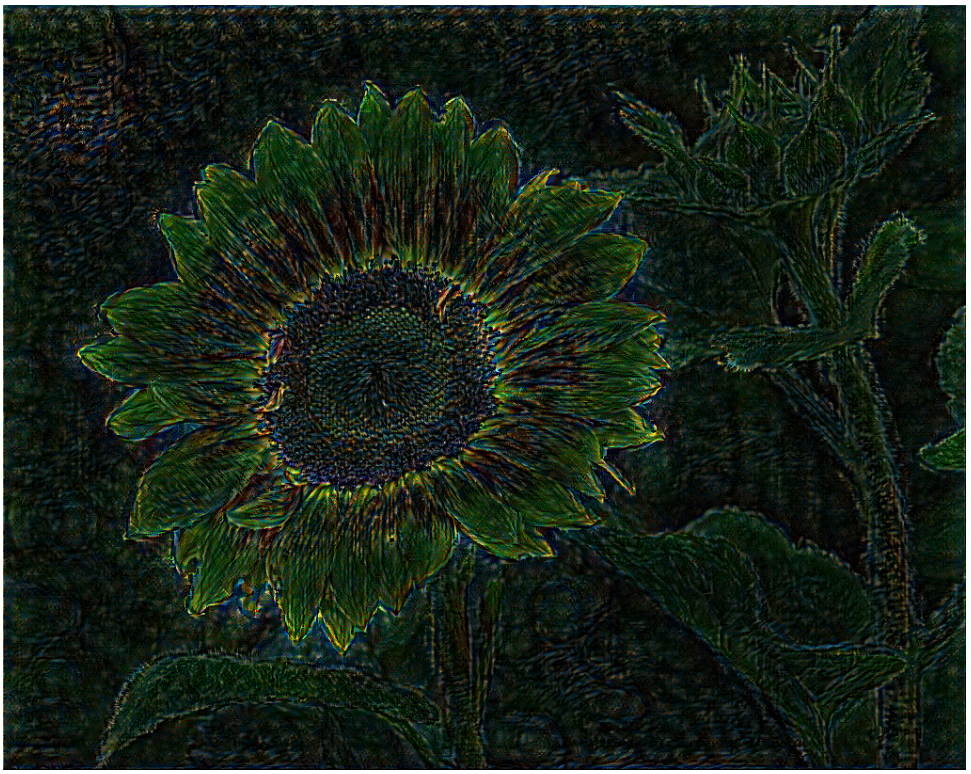
- Adam:
  - 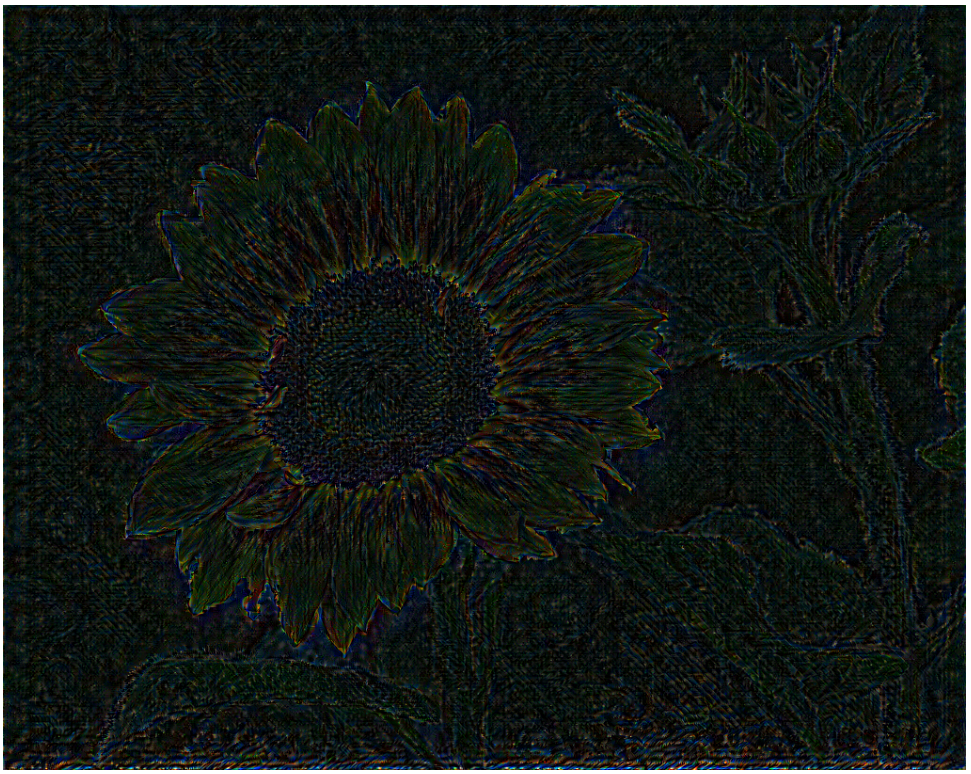
- 并且在小登选定的范围内**改变风格权重和总变分权重**，Adam 的图片结果基本没有变化，L-BFGS在风格权重减小或者总变分权重增大时，花朵**明显变暗**。
- 风格权重较大或者总变分权重较小：

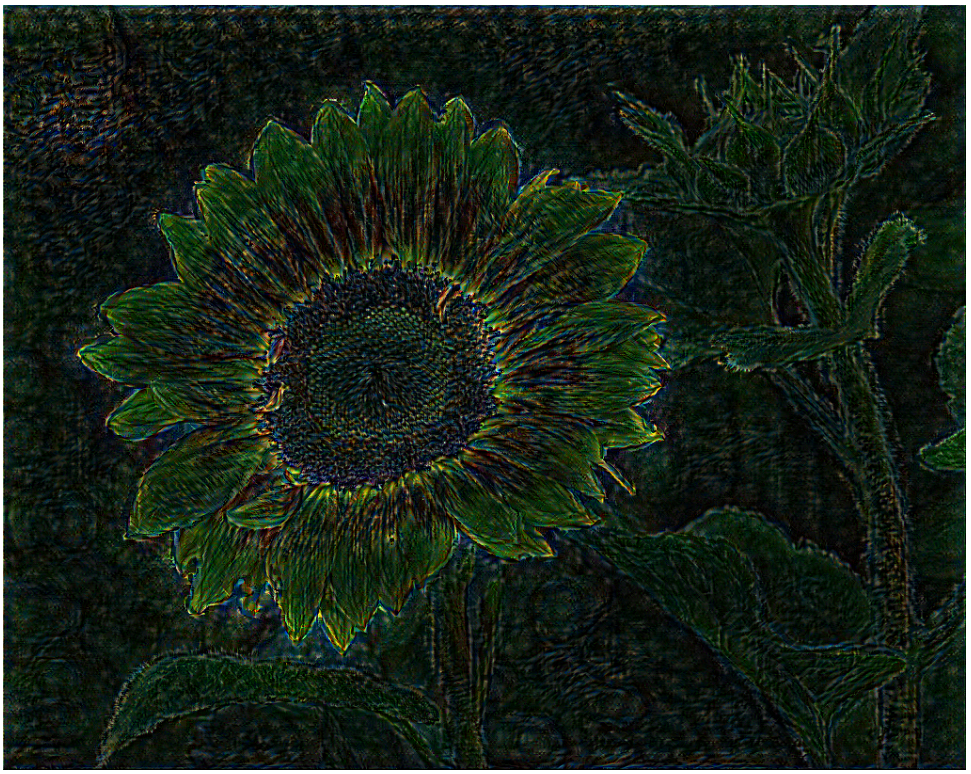

- 风格权重较小或者总变分权重较大：

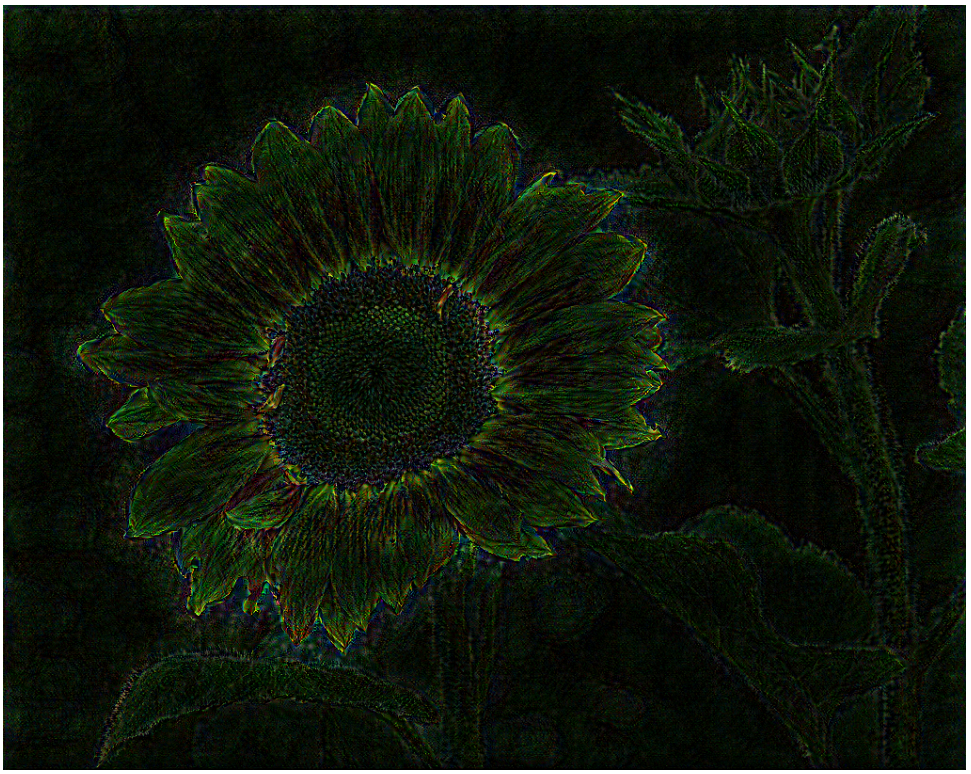

  - **原因**：
    - L-BFGS 在这种情况下**参数更新的更快，审美效果更好**。
    - Adam **本来就很暗**，在此基础上变暗变亮**效果不明显**。
  - 再次证明 **损失相似或者更小，审美效果不一定更好。**
    - 这也可能与**某些损失与其他损失相比，数量级更小**有关。

- 总变分函数**取平方 vs 取绝对值**：
  - 在小登的实验中，最开始把像素压缩到 **0-1**，每次更新后都会去除 **0-1** 之外的数值。
  - 因此，**与取绝对值相比，取平方得到的总变分函数数量级更小，梯度也更小**。
  - 在权重一致时，这个差距在 **10** 倍左右。
- **风格权重与总变分损失权重左脚踩右脚上天：**

    - 在小登的实验过程中，生成图片**噪点较多**一直是问题（**目前这个问题仍然明显**）。
    - 于是小登为了降噪，提升了总变分损失权重，但导致风格不太明显。又为了加强风格，小登直接调大风格权重。再之后，两个风格的权重就**爆炸**了，但是问题还没得到解决。
    - 但是在最初的基础上，**降低风格权重后，风格迁移效果也还可以，噪点问题也减弱了**。
    - 小登认为，由于**风格损失的计算使用的是 Gram 矩阵，风格迁移大多体现在增加细节的纹理和笔触，而非整体的结构。这些细节上的改变可能是噪点问题的主要原因。**
    - 正因此，**降低权重后，噪点问题也能得到解决**。
- **风格损失算法对风格迁移效果的影响**：
    - 小登发现，在实验过程中，风格效果大多体现在增加**细节的笔触和纹理，而不会出现较大的结构上的变化**。
    - 比如，向日葵与星月夜的迁移实验中，细节的**小漩**较多，但是没有出现星月夜上**比较大的漩涡**。
        -

- scene 系列与水墨画的迁移实验中，背景出现了类似水墨画中**竹子形状的小褶皱**，但是没有生成**较大的竹叶**。

-

    - 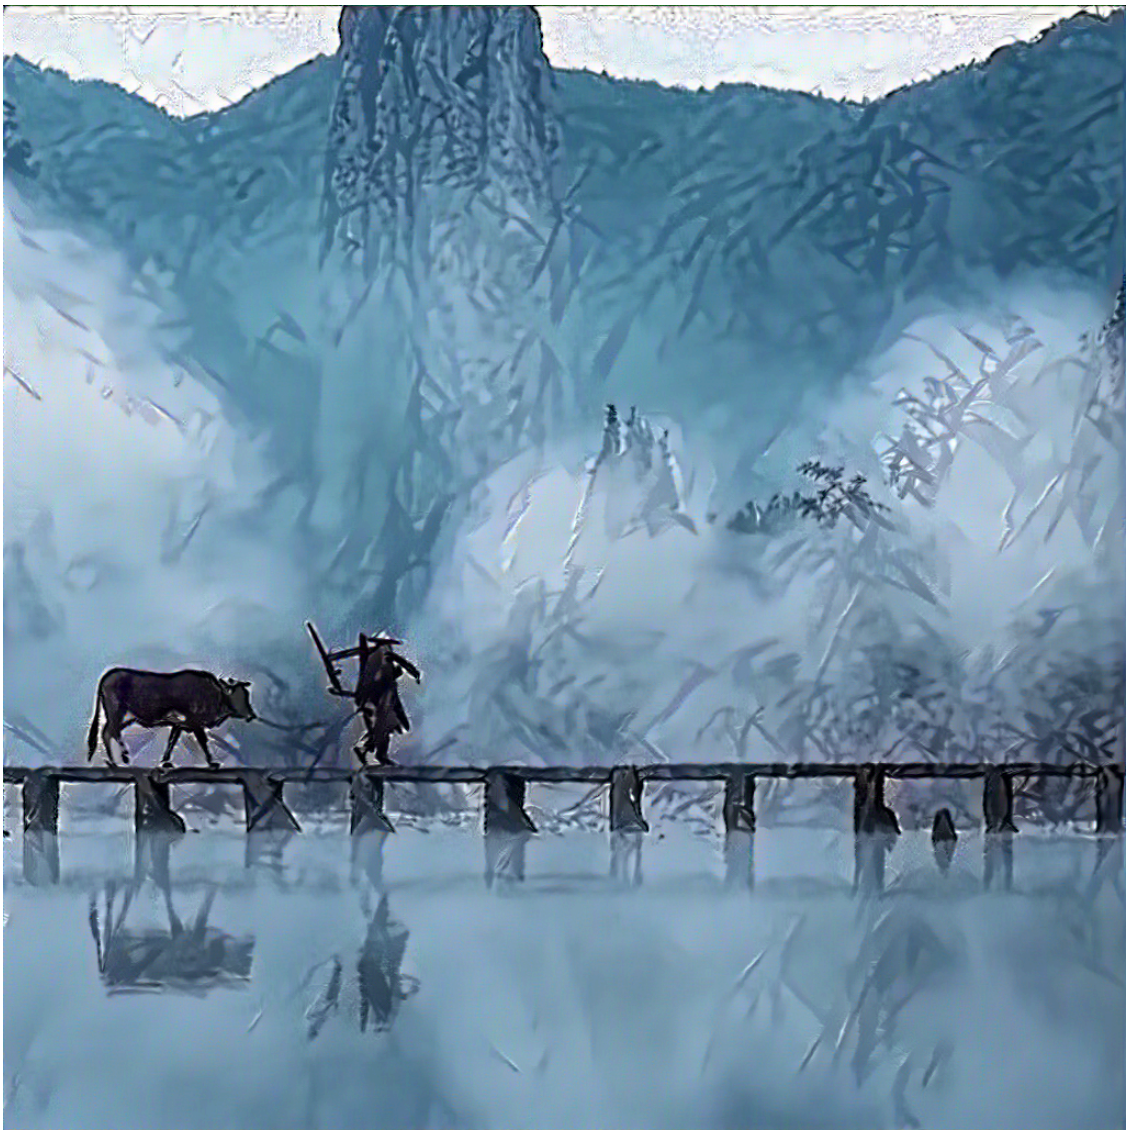
    - 甚至在小登把**构成主义画作迁移到奶龙时，也只出现小的笔触和纹理的改变，没有大的结构变化**。
        - 样图
        -
    - 这可能与 **Gram 矩阵只计算通道之间的整体统计关系有关**。
- **有关初始生成图片的问题**：
    - 小登大部分实验**采用内容图片初始化生成图片**，最终导致**内容损失对损失的贡献较小，风格迁移过程中内容损失不断增大。**
        - **这可能限制风格迁移的效果。**
        - 这种情况下，相比于另外两种损失，风格损失数量级过大，可能使**风格迁移对风格权重不敏感。**
            - 这也许是小登在向日葵与星月夜风格迁移实验中**反复调整风格权重但没有效果**的原因。

        - 也许可以通过白噪音初始化解决这一问题。
    - **小登尝试把零张量当作初始化生成图片**，但是**最终生成的图片像素值太小，图片整体过暗。**
    - **小登暂时只选择了这两种初始化生成图片的方案，没有进行白噪音初始化。如果学长有推荐的方案，请学长赐教。**

问题

- 小登在风格迁移过程中，一直受 **“噪点问题、风格迁移对风格权重不敏感”** 的困扰。
    - 在上述思考中，小登**分析并利用降低风格权重，解决了部分噪点问题**，又认为可能是**图片初始化方式（克隆内容图片）导致对风格权重不敏感**，或许可以利用白噪音初始化解决这个问题。
    - **除此之外，是否还有其他解决方向？如果学长能提供一些方向，小登将不尽感激**。
- 关于小登所作的风格迁移**基本只能改变小的笔触、纹理和细节等**的问题，小登认为可以采用**进阶三——扣轮廓来改进**，除此之外，**还有没有其他方案？**

多谢学长悉心批改题解

Continuing